

УЧЕБНЫЙ МОДУЛЬ · DATA SCIENCE

Извлечение атрибутов из карточек товаров

От правил и NER до мультимодальных моделей: как превратить шумную карточку маркетплейса в структурированные данные, которые двигают поиск и GMV.

Attribute Extraction · Marketplace Catalog

Задача качества каталога, которая влияет на поиск и продажи

ВЫВОД Качество атрибутов напрямую двигает поиск, рекомендации, дедупликацию и unit-экономику.

1

Поиск и фильтры

Незаполненный атрибут =
товар не находится в фильтре

2

Рекомендации

Атрибуты — фичи для
item-to-item и
персонализации

3

Дедупликация

Сопоставление одинаковых
SKU разных продавцов

4

Цена и аналитика

Сравнение, ценообразование,
ассортиментные решения

Атрибут заполнен



Товар попадает в фильтры



Выше CTR и конверсия



Рост GMV

Извлечение атрибутов — это про деньги в поиске и каталоге, а не ML-упражнение ради метрики.

Что именно мы извлекаем

ВЫВОД Задача — превратить полуструктурированную карточку в нормализованный набор (атрибут, значение, уверенность)

ВХОД · КАРТОЧКА

- Описание (свободный текст)
- Атрибуты от продавца



ПАЙПЛАЙН ИЗВЛЕЧЕНИЯ

Распознать значение
+ нормализовать
+ оценить уверенность



ВЫХОД · СТРУКТУРА

```
{  
  "бренд": "Samsung",  
  "память": "256 ГБ",  
  "экран": "6.7 дюйма",  
  "цвет": "чёрный"  
}
```

Смартфон → бренд, модель, объём памяти, диагональ экрана, ёмкость батареи, цвет

Ноутбук → бренд, процессор, объём RAM, накопитель, диагональ, цвет

Барьеры сложности

Вывод Сложность не в одной модели, а в масштабе, длинном хвосте, мультимодальности и нормализации одновременно.

1

Огромная таксономия

Тысячи категорий × десятки атрибутов в каждой.

2

Длинный хвост (long tail)

Редких значений много, но примеров по каждому мало.

3

Неоднозначность

Нормализация: «алый» = «красный» = «red»


4

Масштаб и дрейф

Новые SKU и категории каждый день.

Метрики качества

ВЫВОД Per-attribute precision/recall важнее общей accuracy



1

F1 по каждому атрибуту

Не средняя ассурасу — она маскирует провал на хвосте.

2

Coverage

Доля карточек, где атрибут заполнен.

3

Взвешивание по трафику

Важнее атрибуты, по которым реально фильтруют.


4

Human eval на gold-сете

Эталон, размеченный людьми, по категориям.

Эволюция подходов

ВЫВОД Это путь компромиссов «покрытие ↔ стоимость ↔ поддерживаемость», а не «новое всегда лучше».



В продакшене эти подходы сосуществуют, а не вытесняют друг друга.

Базлайн: правила и словари

ВЫВОД Regex дают значимую часть результата быстро и остаются опорой для проверки моделей.

ВХОД: "Футболка мужская хлопок 100% размер XL красная" → **ПРАВИЛО:** regex размера `/b(XS|S|M|L|XL)\b/` + словарь цветов

ВЫХОД: { размер: "XL", цвет: "красный", материал: "хлопок", пол: "мужской" }

Плюсы

- Прозрачность и контроль
- Скорость, ноль обучающих данных
- Идеален как honest baseline

Минусы

- Не масштабируется на хвост
- Хрупкость к формулировкам
- Ручная поддержка словарей

NER и sequence labeling

ВЫВОД Извлечение атрибутов естественно сводится к разметке последовательностей токенов BIO-тегами.


Футболка	мужская	хлопок	размер	XL	красная
О	В-ПОЛ	В-МАТ	О	В-РАЗМ	В-ЦВЕТ

Токены → BIO-теги атрибутов (В — начало значения, I — внутри, О — вне атрибута)

Где выигрывает у правил: ловит значения в свободном тексте и неожиданных формулировках. **Цена:** нужна размеченная обучающая выборка.

Дообученный энкодер под извлечение

Вывод Fine-tune BERT хорошо работает на свободном тексте и контекстных формулировках, но для длинного хвоста всё равно нужны данные и справочники



Multi-task: один энкодер — несколько голов по атрибутам

+ Скачок качества

на хвосте и в свободном тексте

+ Multilingual


один энкодер на разные языки

– Стоимость

данные, инференс, поддержка

Возможность использовать изображение

Вывод В этом задании — только текст



Атрибут	Где сигнал
Бренд	Текст
Размер	Текст
Цвет	Фото (часто)
Принт / узор	Только фото
Форма / фасон	Фото

Кейс: описание молчит про цвет и узор — фото даёт оба атрибута. Цена: усложнение пайплайна и рост стоимости инференса



LLM: zero/few-shot и structured output

Вывод LLM закрывают холодный старт и длинный хвост, но требуют контроля галлюцинаций и стоимости.

Критерий	Fine-tuned энкодер	LLM (few-shot)
Cold-start (новые категории)	Слабо — нужна разметка	Сильно — без разметки
Длинный хвост	Средне	Сильно
Стоимость инференса	Низкая	Высокая
Латентность	Низкая	Высокая
Риск галлюцинаций	Низкий	Требует контроля

Прагматичный паттерн: LLM полезны для cold-start и предразметки, но в production их нужно ограничивать схемой, справочниками, проверкой источника значения и порогами уверенности

Сравнение подходов — решающий слайд


ВЫВОД Правильный ответ — гибрид: правила для ядра, модели для хвоста, LLM для cold-start.

	Качество на хвосте	Стоимость инференса	Нужны данные	Поддерживаемость	Cold-start
Правила	Низко	Очень низко	Нет	Средне	Высоко
NER	Средне	Низко	Средне	Средне	Низко
Трансформер	Высоко	Средне	Много	Средне	Низко
Мультимодал	Высоко	Высоко	Много	Низко	Низко
LLM	Высоко	Высоко	Мало	Высоко	Очень высоко

Красное = сильная сторона подхода. Ни один столбец не закрывается одним подходом — отсюда гибрид.

Продакшен-пайплайн end-to-end


ВЫВОД Извлечь значение недостаточно — его нужно привести к формату маркетплейса и проверить



Петля обратной связи: ошибки и low-confidence случаи → ручная разметка → дообучение / обновление правил → улучшение пайплайна

Данные и стратегия разметки

ВЫВОД Данные — главное конкурентное преимущество. Разметку нужно проектировать, а не докупать объёмом.



- 1 Active learning**
Размечаем то, в чём модель не уверена.
- 2 Weak supervision**
Правила и эвристики как дешёвые лейблы.
- 3 LLM-assisted разметка**
LLM пред-размечает, человек верифицирует.
- 4 Gold-сети по категориям**
Эталон для честной оценки и контроля дрейфа.



Риски и типичные ошибки

Вывод Главные риски — галлюцинации LLM, распространение ошибок в поиск и слепые зоны оценки.

Риск	Последствие	Меры снижения
Галлюцинации LLM	Ложные атрибуты ломают фильтры	Structured output + порог уверенности
Стоимость при масштабе	LLM дорого на каждый SKU	Дистилляция, кэш, гибридный роутинг
Eval не покрывает хвост	Метрика красивая, качество плохое	Gold-сеты по редким категориям
Дрейф новых категорий	Падение качества во времени	Мониторинг + петля дообучения
Несправедливость к продавцам	Мелкие SKU хуже обрабатываются	Контроль покрытия по сегментам

На уровне VP первым делом спрашивают про риски — не прячьте их, показывайте вместе с мерами снижения.

ЗАДАНИЕ

Что нужно сделать

Вывод Построить пайплайн, который извлекает обязательные атрибуты из текста карточек

1 Вход — текст карточки
Заголовок, описание и атрибуты продавца

2 Извлечь и нормализовать
Достать обязательные поля и привести значения к каноническому виду.

3 Бейзлайн → модель
Начать с правил/словарей, затем попробовать ML- или LLM-подходом

4 Оценить честно
Per-attribute precision / recall / F1 на gold-сете

ЧТО ПРЕДОСТАВЛЯЕМ

Датасет и обязательные поля

Что будет представлено: датасет карточек товаров и список обязательных атрибутов для извлечения

Датасет карточек товаров

- Текстовые поля: описание, атрибуты продавца
- Размеченная часть для обучения и валидации
- Разные категории товаров (электроника и др.)
- Формат (CSV / JSON)

Обязательные поля для извлечения

- Бренд
- Модель
- Ключевые характеристики (память, диагональ, цвет...)
- Каждое поле — со значением и уверенностью

Точный перечень обязательных полей фиксируется вместе с датасетом.

СДАЧА РАБОТЫ

Обязательные артефакты

ВЫВОД Работа принимается комплектом из шести артефактов.

1

Код или ноутбук

Воспроизводимый код решения

2

README

Инструкция установки и запуска

3

EDA по данным

Анализ полей, пропусков, распределений

4

Пайплайн извлечения

От текста карточки до атрибутов

5

Файл с результатами

Предсказанные атрибуты по карточкам

6

Финальная презентация

Подход, метрики и выводы

Формат сдачи: один репозиторий или архив; запуск решения воспроизводится по README